


# ① LDA

\* 분류를 위한 베이즈 정리 사용.

< 기본 idea >



① 데이터 (X)로부터 사전 확률  $P(w_1)$ ,  $P(w_2)$  도출.

1)  $P(w_1) = \frac{w_1}{w_1 + w_2}$ , 2)  $P(w_2) = \frac{w_2}{w_1 + w_2}$

(범주가  $w_1$ 인 데이터 개수,  $w_2$ 인 데이터 개수를 각각 전체 데이터 개수로 나눠주기)

② 새로운 데이터 (x)가 주어졌을 때, x가 어느 클래스에 속할지 맞추기.

$$P(w_i | x) = \frac{P(x|w_i) \cdot P(w_i)}{P(x)}$$


$$= \frac{P(x|w_1) \cdot P(w_1)}{P(x|w_1) \cdot P(w_1) + P(x|w_2) \cdot P(w_2)}$$

< 분류 메커니즘 >

· 새로운 데이터 x 등장.

· LDA 모델  $\rightarrow P(w_1|x)$ ,  $P(w_2|x)$  각각 도출.

· 둘 중에 높은 확률이 나오는 곳에 x를 배정.



1)  $P(w_1|x) > P(w_2|x) \rightarrow x = w_1$   
2)  $P(w_1|x) < P(w_2|x) \rightarrow x = w_2$

< 개념 >

① 벡터, ② 공분산, ③ 행렬, ④ 정규분포 밀도함수.

\* 정규분포를 따르는 N개의 데이터가 k개 범주로 구성되어 있는

① 벡터

$$\mu = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_p \end{bmatrix}$$

Column Vector

② 공분산

$$\Sigma = \begin{bmatrix} \sigma_{11} & \dots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \dots & \sigma_{pp} \end{bmatrix}$$

$$* COV(X, Y) = E((X - \mu_x)(Y - \mu_y))$$

$\rightarrow$  X와 Y 두 변수의 변동은 나타냄.

$COV(X, Y) > 0$  : X가 증가할 때 Y도 증가 (양의관계)  
"  $< 0$  : " " Y 감소 (부의관계)  
"  $= 0$  : 서로 독립.

② 행렬

1) Transposed Matrix  $\Rightarrow W^T$ , w행렬의 전치행렬.

$$A = \begin{bmatrix} 1 & 1 & 1 & 1 \\ -3 & -5 & 6 & 8 \end{bmatrix} \quad A^T = \begin{bmatrix} 1 & -3 \\ 1 & -5 \\ 1 & 6 \\ 1 & 8 \end{bmatrix}$$

2) Inverse Matrix

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \quad A^{-1} = \frac{1}{ad-bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} \quad \text{단, } ad-bc \neq 0.$$

$$A \cdot A^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = E$$

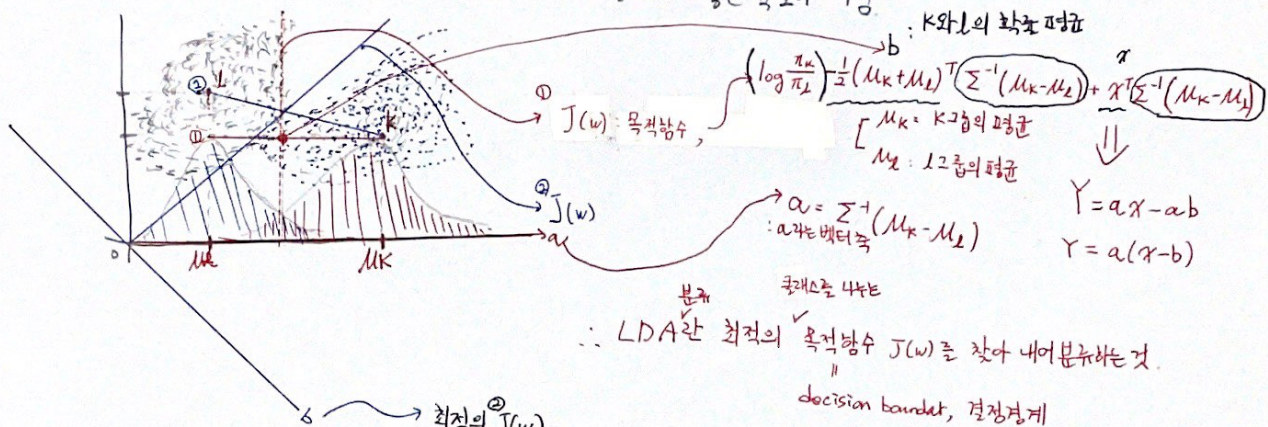
단위행렬



## ② LDA. (쉬운 ver)

①  $J(w) = |\tilde{\mu}_1 - \tilde{\mu}_2| = |w^T(\mu_1 - \mu_2)|$  : 중심(평균)간의 거리  $\rightarrow$  목적함수  $=$  '평균의 차이' 최대

$\rightarrow$  ① 평균만 고려한다면, ② 분산(편차)가 고려되지 않으므로 좋은 척도가 아님



<학문도형적 접근 - 베이저안들>

②.  $\gamma$ 가 k개의 범주를 가질 때,  $k=1, 2, \dots, K$

LDA 가정. ① 각 클래스 집단은 정규분포 형태의 확률분포를 갖는다.  
 ②. " " " " 비수단 형태의 공분산 구조를 갖는다.

$\gamma = k$  일 때, 공분산 구조를 갖는  $\Sigma_k$ 를 갖는 P개의 정규분포 변수의 분포.

$$f_k(x) = \frac{1}{(\sqrt{2\pi})^P \sqrt{|\Sigma_k|}} \exp\left(-\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k)\right)$$

\* 정규분포 밀도함수

$$f(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$\rightarrow$  이때, 아래의 로그 값이 클수록,  $\lambda$  대비  $k$  범주에 속할 확률이 높아진다.

$$\log \frac{P(k|x)}{P(l|x)} = \log \frac{f_k(x)}{f_l(x)} + \log \frac{\pi_k}{\pi_l}$$

\* 다변량 정규분포,  $\mu$ ,  $\Sigma$  (공분산)

$$f(x) = \frac{1}{(2\pi)^{P/2} |\Sigma|^{1/2}} \exp\left\{-\frac{(x-\mu)^T \Sigma^{-1} (x-\mu)}{2}\right\}$$

$\rightarrow$  위의 식은,  $k$ 와 관계없는 공분산 구조  $\Sigma$ 를 갖기 때문에, 아래와 같은  $x$ 에 대한 식으로 정리 가능.

$$\log \frac{P(k|x)}{P(l|x)} = \log \frac{f_k(x)}{f_l(x)} + \log \frac{\pi_k}{\pi_l} = \log \frac{\pi_k}{\pi_l} - \frac{1}{2} (\mu_k + \mu_l)^T \Sigma^{-1} (\mu_k - \mu_l) + x^T \Sigma^{-1} (\mu_k - \mu_l)$$

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k \text{ 라고 하면,}$$

$$\log \frac{P(k|x)}{P(l|x)} = \delta_k(x) - \delta_l(x) = \text{① 분산은 최소화, ② 평균은 최대화}$$



### ③ LDA & QDA (어려운 ver.)

· 다변량 정규분포.

$$P(x|w_i) = \frac{1}{(2\pi)^{p/2} |\Sigma_i|^{1/2}} \exp\left[-\frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1}(x-\mu_i)\right]$$

· 판별함수  $\delta_i(x) = P(w_i|x) \rightarrow P(x|w_i) \cdot P(w_i) \rightarrow \ln P(x|w_i) + \ln P(w_i)$

↳ 새로운 데이터  $x$  에 대한 범주를 찾다.

· 판별함수는 다변량 정규분포에 대입

판별함수 Sol)  $\ln P(x|w_i) = \ln \frac{1}{(2\pi)^{p/2} |\Sigma_i|^{1/2}} - \frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1}(x-\mu_i)$

$$= \ln \frac{1}{(2\pi)^{p/2}} + \ln \frac{1}{|\Sigma_i|^{1/2}} - \frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1}(x-\mu_i)$$

$$= \underbrace{-\frac{p}{2} \ln 2\pi}_{\text{알고있는 값}} - \frac{1}{2} \ln |\Sigma_i| - \frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1}(x-\mu_i) \quad : \text{상수.}$$

결정경계 Sol)  $\delta_1(x) - \delta_2(x) = 0$

$$-\frac{p}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_1| - \frac{1}{2}(x-\mu_1)^T \Sigma_1^{-1}(x-\mu_1) + \ln P(w_1) - \left( -\frac{p}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_2| - \frac{1}{2}(x-\mu_2)^T \Sigma_2^{-1}(x-\mu_2) + \ln P(w_2) \right) = 0$$

$$(x-\mu_1)^T \Sigma_1^{-1}(x-\mu_1) - (x-\mu_2)^T \Sigma_2^{-1}(x-\mu_2) - \ln \frac{|\Sigma_2|}{|\Sigma_1|} + 2 \ln \frac{P(w_1)}{P(w_2)} = 0$$

1)  $\Sigma_1 = \Sigma_2$  가정. (각 범주의 공분산이 동일하다고 가정)  $\rightarrow$  LDA

by. Pooled Variance (합동분산)  $\Sigma_1 = \Sigma_2 = \Sigma = \left[ \frac{n_1-1}{(n_1-1)(n_2-1)} \right] \cdot \Sigma_1 + \left[ \frac{n_2-1}{(n_1-1)(n_2-1)} \right] \Sigma_2$

위의 식을 판별함수에 대입.

$$(\mu_1 - \mu_2)^T \Sigma^{-1} \left( x - \frac{1}{2}(\mu_1 + \mu_2) \right) - \ln \frac{P(w_1)}{P(w_2)} = 0$$

$\Rightarrow Ax + b = 0$  의 선형식 (Linear Equation) 도출.

:  $x$  를 넣어 0보다 큰 값이 나오면  $w_1$  범주 그렇지 않으면  $w_2$  범주로 분류.

2)  $\Sigma_1 \neq \Sigma_2$  가정.  $\rightarrow$  QDA (Quadratic Discriminant Analysis)

Sol)  $-\frac{1}{2}x^T(\Sigma_1^{-1} - \Sigma_2^{-1}) \cdot x + (\mu_1 \Sigma_1^{-1} + \mu_2 \Sigma_2^{-1})x - \frac{1}{2}(\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1}) + \frac{1}{2} \ln \frac{|\Sigma_2|}{|\Sigma_1|} - \ln \frac{P(w_1)}{P(w_2)} = 0$

$\Rightarrow Ax^2 + bx + c = 0$  의 2차식처럼 보임.